

Estudio de algunas propiedades del método de clustering k-modes mediante remuestreo

Diego Araújo¹ -Ramón Álvarez-Vaz¹ - Mauro de la Vega²

Instituto de Estadística, Facultad de Ciencias Económicas y de Administración, Universidad de la República, Uruguay¹

Unidad Curricular Finanzas Corporativas, Facultad de Ciencias Económicas y de Administración, Universidad de la República, Uruguay²

Resumen

Existen muchas situaciones en muy variadas disciplinas como la economía, el marketing, la epidemiología, donde la matriz de datos de la que se dispone está formada por datos binarios (unos y ceros) que surgen de trabajar con varias variables aleatorias resultantes de un experimento con 2 resultados posibles en cada caso. Muchas veces interesa analizar la relación entre variables y formar a su vez grupos que den cuenta de esas relaciones. En este documento se presenta el estudio de la performance de un método de clustering, el kmodes de perfil modal, teniendo en cuenta la variabilidad de algunas métricas que permiten evaluar la homogeneidad de los grupos y decidir una posible solución a la cantidad de grupos. Esa variabilidad se estudió en función del arranque el método , que es aleatorio en la elección de centros, viendo de ese modo la dependencia con la solución encontrada y también en la estructura de los datos por lo cual se trabaja con muestras de aprendizaje, variando el tamaño de la misma mediante remuestreo. Se trabaja con datos que surgen de un estudio en el campo de las finanzas corporativas, desarrollado durante la pandemia en Uruguay, donde se indaga acerca del IMPACTO COVID-19 EN LAS EMPRESAS URUGUAYAS en la toma de decisiones sobre reducción de personal, teletrabajo, capacitación y ambiente laboral entre otras.

Presentación del Problema

El problema de interés que nos ocupa es estudiar las propiedades del algoritmo en cuanto a su estabilidad bajo distintos escenarios, evaluando su rendimiento a través de distintas métricas y logrando aproximarnos a una cantidad k óptima de grupos, un problema común en este tipo de análisis. El algoritmo $kmodes$ así como su similar para datos numéricos ($k-means$), se encuentra afectado por los arranques aleatorios y en este caso también por el tamaño de la muestra. Es así que se proponen 2 escenarios:

- **Escenario 1:** Trabajar con una muestra de tamaño fijo y arranques aleatorios.
- **Escenario 2:** Haciendo remuestreo a distintos niveles (70 %, 80 % y 90 %) de la muestra original, para un k fijo.

Metodología de Análisis

Se utiliza parte de la metodología propuesta por Alvarez-Vaz y Massa para encontrar perfiles de infección parasitaria en escolares de Montevideo (1). En este caso el algoritmo $k-modes$, que es de tipo *modal*, y que no es más que un caso particular descrito por Huang (5).Tiene una lógica de funcionamiento similar a la del algoritmo $k-means$, y dada la naturaleza de las variables (binarias), es necesario el uso de otras medidas de disimilaridad, usando un método basado en frecuencias para actualizar los modos (9).

Formulación del algoritmo

El algoritmo $k-modes$ aplica la siguiente disimilaridad, siendo x_i, y_j 2 individuos de los que se mide los atributos:

$$d(x_i, y_i) = \sum_1^m \delta(x_j, y_j) \quad , \text{ con } \delta(x_j, y_j) = \begin{cases} 0 & \text{si } x_j = y_j \\ 1 & \text{si } x_j \neq y_j \end{cases}$$

El algoritmo trabaja de la siguiente manera, en 4 pasos:

- ➊ Selecciona k modos iniciales, que actuarán como centroide de cada cluster, con x , y variables categóricas binarias en este caso;
- ➋ Calcula la cantidad de disimilitudes de cada individuo con dichos modos y lo agrupará con el centroide que presente menor cantidad de diferencias (mayor similaridad);
- ➌ Luego de que todos los individuos han sido asignados, reestima la disimilaridad de los objetos contra el actual modo y si encuentra que un individuo tiene un modo de otro grupo que está más próximo lo reasigna, actualizando los modos de ambos grupos que se modificaron;
- ➍ Se repite el paso 2 hasta que ningún individuo haya cambiado de cluster hasta haber visitado todo el conjunto de datos.

El resultado de este algoritmo es, entonces, una partición de los individuos en grupos cuyo representante es el perfil modal, es decir la combinación de respuestas que es más frecuente en cada cluster.

Métricas de validación

Se proponen 3 métricas para realizar la validación interna de los cluster y evaluar tanto la compacidad de los grupos (homogeneidad), como la separación entre ellos.

- **Diferencias Intracluster Absolutas:** Cantidad total de diferencias que hay dentro de cada cluster, de cada elemento con respecto al perfil modal del grupo.
- **Diferencias Intracluster Relativas:** Cantidad total de diferencias dentro de cada cluster, pero condicionadas a la cantidad de elementos del grupo.
- **Coefficiente de silueta:** Métrica utilizada para calcular que tan bien se agrupan las observaciones o elementos. Su valor oscila entre -1 (los grupos se asignan de forma incorrecta) y 1 (los grupos están bien separados entre sí y claramente diferenciados). Para una observación i se define como:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))}$$

dónde $a(i)$ es el promedio de disimilaridades de i con el resto de observaciones que pertenecen al mismo cluster que i y $b(i)$ es el promedio de disimilaridades de i con los elementos del cluster más cercano.

Referencias Bibliográficas

[1] Álvarez-Vaz, R. y Massa, F. (2012). Determinación de tipologías de infecciones parasitarias intestinales, en escolares mediante técnicas de clustering sobre datos binarios. Documento de Trabajo Serie DT (12 / 05) - ISSN : 1688-6453, IESTA.

[2] Borgatti, S. P., Everett, M. G., y Johnson, J. (2013). *Analyzing Social Networks*. SAGE Publications Ltd.

[3] Brealey, R., Myers, S., y Allen, F. (2011). *Principles of Corporate Finance*. McGraw-Hill / Irwin., New York.

[4] Graham, J. R. y Harvey, C. R. (2001). The theory and practice of corporate finance: Evidence from the field. *Journal of Financial Economics*, 60(2):187–243.

[5] Huang, Z. (1997). A fast clustering algorithm to cluster very large categorical data sets in data mining. in kdd: Techniques and applications. Technical report.

[6] Kolaczyk, E. y Csárdi, G. (2014). *Statistical analysis of network data with R*. Springer, New York.

[7] R Core Team (2017). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.

[8] Tsekouras, G., Papageorgiou, D., Kotsiantis, S., Kalloniatis, C., y Pintelas, P. (2005). Fuzzy clustering of categorical attributes and its use in analyzing cultural data. *World Academy of Science, Engineering and Technology*, 1:87–91.

[9] Weihs, C., Ligges, U., Luebke, K., y Raabe, N. (2005). Klar analyzing german business cycles. En Baier, D., Decker, R., y Schmidt-Thieme, L., editores, *Data Analysis and Decision Support*, pp. 335–343, Berlin. Springer-Verlag.

[10] Martin Maechler and Peter Rousseeuw and Anja Struyf and Mia Hubert and Kurt Hornik cluster: Cluster Analysis Basics and Extensions

Descripción del problema en estudio

Los datos utilizados parten de una investigación en la cuál se intentó profundizar sobre las medidas implementadas en el contexto de la pandemia de Covid-19 a través de una muestra de empresas uruguayas y observar como fueron afectadas sus finanzas (ver más detalles en link). De una muestra de 700 empresas, 112 de ellas (un 16 %) respondieron a una encuesta electrónica donde se trató de cubrir todos los aspectos necesarios para la investigación, conociendo a su vez atributos de las empresas. Los datos quedaron resumidos en los siguientes bloques:

- Efectos de la pandemia sobre las finanzas de las empresas (EF).
- Medidas implementadas por las empresas para sostener el negocio (MI).
- Medidas ofrecidas por el gobierno y utilizadas en las empresas (MG).
- Cambios tecnológicos que tuvieron que realizar las empresas (CT).

Lo que se presenta en este documento surge de trabajar sobre el bloque EF, que se detalla a continuación:

Variable	Descripción	Bloque	Tipo	Proporción
V1	Uso de indicadores económico-financieros	1	Estado financiero	55.4 %
V2	Flujo de fondos para evaluar liquidez	1	Estado financiero	70.5 %
V3	Afecta Flujo de Efectivo	2	Efecto en la empresa	64.3 %
V4	Afecta Volumen de Ventas	2	Efecto en la empresa	63.4 %
V5	Afecta Capital de Trabajo	2	Efecto en la empresa	50.9 %
V6	Afecta Ciclo de cuentas a cobrar	2	Efecto en la empresa	64,3 %
V7	Afecta Tiempo de abastecimiento Materias Primas	2	Efecto en la empresa	40.2 %

Cuadro 1: Bloque de variables de efectos de la pandemia sobre las finanzas de la empresa.

En cada uno de los escenarios descriptos, se evalúa el comportamiento de las distintas métricas propuestas, para observar su adecuación al problema y lograr determinar una cantidad de grupos “óptima”.

Resultados

Para el análisis global se trabaja con el software libre R (7), para la determinación de los clusters con el algoritmo presentado en la metodología se usa la librería $kmodes$ (9) y el paquete $cluster$ (10) para los coeficientes de silueta.




Figura 1: Proporción de las variables en cada grupo (2 grupos).




Figura 2: Proporción de las variables en cada grupo (3 grupos).




Figura 3: Proporción de las variables en cada grupo (4 grupos).




Figura 4: Gráficos de silueta para distintos k ($k = 2,3,4$). El coeficiente de silueta más alto se da para 2 grupos (Average silhouette width = 0.37)

k-modes con 2 clusters	1	2		
tamaño	70	42		
withindiff	131	77		
densidad	1.87	1.83		
coef. silh.	0.39	0.34		
k-modes con 3 clusters	1	2	3	
tamaño	70	31	11	
withindiff	131	51	15	
densidad	1.87	1.65	1.36	
coef. silh.	0.26	0.26	0.37	
k-modes con 4 clusters	1	2	3	4
tamaño	56	29	11	16
withindiff	91	44	15	17
densidad	1.62	1.52	1.36	1.06
coef. silh.	0.08	0.29	0.27	0.38

Cuadro 2: Métricas para validación de los grupos.




Figura 5: Escenario 1. Métricas para distintos k y arranques aleatorios. De izquierda a derecha: Díf. intracluster absolutas, relativas y coeficiente de silueta.




Figura 6: Escenario 2. Métricas para k=2 y remuestreo a distintos niveles. Diferencias relativas (izquierda) y Coeficiente de silueta (derecha).

Conclusiones

Discusión Escenario 1:

Para el escenario donde se prueban varios k , se puede ver que a medida que se va desagregando en más grupos, la homogeneidad va aumentando. Las dos primeras métricas se ven muy afectadas por esto, sin embargo la silueta no solo mide que tan homogéneo es un grupo, sino que tan diferente es al grupo más cercano, por lo que es una medida más fiable. A través de esto se llega a un k ”óptimo.”

Discusión Escenario 2:

Con el k hallado a través del escenario 1, se prueba la clusterización a distintos niveles de muestreo. Las 2 primeras métricas, reflejan que un tamaño menor de muestra tiene mayor homogeneidad (?), en el de silueta no es muy claro. No se ve muy claro el tema de la estabilidad tampoco, dejó un boxplot (por probar otra cosa) dentro de fig que se levemente la mayor mediana al 90 %, y el rango un poco menor que en las demás, pero no lo veo claro.