

See discussions, stats, and author profiles for this publication at: <https://www.researchgate.net/publication/388891239>

ESTUDIO DE ALGUNAS PROPIEDADES DEL MÉTODO DE CLUSTERING K-MODES MEDIANTE REMUESTREO

Conference Paper · June 2022

DOI: 10.5281/zenodo.10993488

CITATIONS

0

READS

8

3 authors, including:



[Ramón Álvarez-Vaz](#)

Universidad de la República de Uruguay

260 PUBLICATIONS 518 CITATIONS

[SEE PROFILE](#)



[Mauro de la Vega](#)

Universidad de la República de Uruguay

6 PUBLICATIONS 0 CITATIONS

[SEE PROFILE](#)

ESTUDIO DE ALGUNAS PROPIEDADES DEL MÉTODO DE CLUSTERING K-MODES MEDIANTE REMUESTREO

DIEGO ARÁUJO ^a, RAMÓN ÁLVAREZ-VAZ ^a, MAURO DE LA VEGA ^b

^aInstituto de Estadística,
Facultad de Ciencias Económicas y de Administración,
Universidad de la República de Uruguay
e-mail: diego.araujo@fcea.edu.uy, ramon.alvarez@fcea.edu.uy

^bUnidad Curricular Finanzas Corporativas,
Facultad de Ciencias Económicas y de Administración,
Universidad de la República de Uruguay
e-mail: mauro.delavega@fcea.edu.uy

En este documento se presenta el estudio de la performance de un método de clustering, el kmodes de perfil modal, teniendo en cuenta la variabilidad de algunas métricas que permiten evaluar la homogeneidad de los grupos y decidir una posible solución a la cantidad de grupos. Esa variabilidad se estudió en función del arranque el método, que es aleatorio en la elección de centros, viendo de ese modo la dependencia con la solución encontrada y también en la estructura de los datos por lo cual se trabaja con muestras de aprendizaje, variando el tamaño de la misma mediante remuestreo.

Se trabaja con datos que surgen de un estudio en el campo de las finanzas corporativas, desarrollado durante la pandemia en Uruguay, donde se indaga acerca del IMPACTO COVID-19 EN LAS EMPRESAS URUGUAYAS en la toma de decisiones sobre reducción de personal, teletrabajo, capacitación y ambiente laboral entre otras.

Keywords: Clustering, K-Modes, Remuestreo, Variables Categóricas.

1. Introducción

El trabajo aquí presentado deriva de una investigación que se realizó sobre una muestra de empresas uruguayas, de forma de conocer el impacto que tuvo la pandemia del Covid-19 sobre las finanzas de las mismas, las medidas tuvieron que implementar para poder dar continuidad a sus negocios, las opciones brindadas por el gobierno que fueron mayormente utilizadas, entre otros aspectos.

Para poder recolectar estos datos se utilizó un cuestionario de formato electrónico, en el cuál las respuestas a las preguntas enviadas se pueden codificar como unos y ceros ("Si / No"). Por lo que fue conveniente utilizar algún método de clustering para variables categóricas, de forma de crear el perfil modal de estas empresas y ver como quedaban segmentadas a través de distintos bloques de información.

Mas allá del tema inicial que trataba la investigación,

nos fue de interés estudiar las propiedades del algoritmo en cuanto a su estabilidad bajo distintos escenarios, evaluando su rendimiento a través de distintas métricas y logrando aproximarnos a una cantidad k óptima de grupos, un problema común en este tipo de análisis. El algoritmo *kmodes* así como su similar para datos numéricos (*k-means*), se encuentra afectado por los arranques aleatorios y en este caso también por el tamaño de la muestra. Es así que se proponen 2 escenarios:

- **Escenario 1:** Trabajar con una muestra de tamaño fijo y arranques aleatorios.
- **Escenario 2:** Haciendo remuestreo a distintos niveles (70 %, 80 % y 90 %) de la muestra original, para un k fijo.

Para asegurar la reproducibilidad de los resultados del análisis realizado, se dispuso el código y datos utilizados en un repositorio público al que se puede acceder a través de este [link](#)

2. Metodología de Análisis

Se utiliza parte de la metodología propuesta por Tsekouras *et al.* para clasificar atributos categóricos, a través del algoritmo mixto *Fuzzy C-modes* [1], y utilizada por Alvarez-Vaz y Massa para encontrar perfiles de infección parasitaria en escolares de Montevideo [2]. En ambos trabajos cada individuo es previamente clasificado con algún método de clustering y luego pasa por una etapa de difusión, donde pasa a pertenecer a más de un cluster con diferentes grados de participación o membresía. En el método original antes mencionado, se utilizaba el algoritmo *k-modes*, que es de tipo *modal*, y que no es más que un caso particular de un *k-prototipo* descrito por Huang [3]. En este caso, el algoritmo tiene una lógica de funcionamiento similar a la del algoritmo *k-means*, y dada la naturaleza de las variables (binarias), es necesario el uso de otras medidas de disimilaridad, usando un método basado en frecuencias para actualizar los modos [4]. Por lo tanto, del método mixto original planteado por Tsekouras *et al.* [1] se trabaja solamente con el algoritmo *k-modes* que aplica la siguiente disimilaridad, siendo x_i, y_i 2 individuos de los que se mide los atributos:

$$d(x_i, y_i) = \sum_{j=1}^m \delta(x_j, y_j) \quad (1)$$

con:

$$\delta(x_j, y_j) = \begin{cases} 0 & \text{si } x_j = y_j \\ 1 & \text{si } x_j \neq y_j \end{cases} \quad (2)$$

Lo anterior establece la suma de diferencias para cada par de elementos (o individuos) x_i, y_i , en cada j atributo, para tener una idea de la disimilaridad de los mismos. Cuanto más cercano a 0 el valor, más parecidos los elementos. En caso contrario, cuanto más cercano a m (la cantidad de atributos), más diferentes son.

El algoritmo trabaja en 4 pasos, de la siguiente manera:

1. Selecciona k modos iniciales, que actuarán como centroide de cada cluster, con x, y variables categóricas binarias en este caso;
2. Calcula la cantidad de disimilitudes de cada individuo con dichos modos y lo agrupará con el centroide que presente menor cantidad de diferencias (mayor similitud);
3. Luego de que todos los individuos han sido asignados, reestima la disimilaridad de los objetos contra el actual modo y si encuentra que un individuo tiene un modo de otro grupo que está más próximo lo reasigna, actualizando los modos de ambos grupos que se modificaron;
4. Se repite el paso 2 y 3 hasta que ningún individuo haya cambiado de cluster hasta haber visitado todo el conjunto de datos.

El resultado de este algoritmo es, entonces, una partición de los individuos en grupos cuyo representante es el perfil modal, es decir la combinación de respuestas que es más frecuente en cada cluster.

2.1. Métricas de validación. Se proponen 3 métricas para realizar la validación interna de los cluster y evaluar tanto la compacidad de los grupos (homogeneidad), como la separación entre ellos.

- **Diferencias Intracluster Absolutas (DIA):** Cantidad total de diferencias que hay dentro de cada cluster, de cada elemento con respecto al perfil modal del grupo, a través de la medida definida en (1). Para un cluster k dado, se tiene la siguiente expresión:

$$DIA(k) = \sum_{i=1}^{n_k} d(x_i, y_k) \quad (3)$$

dónde n_k es la cantidad de elementos en el cluster k y y_k el centroide del grupo (en este caso el modo o perfil modal).

- **Diferencias Intracluster Relativas (DIR):** Cantidad total de diferencias dentro de cada cluster, pero condicionadas a la cantidad de elementos del grupo. Para un cluster k dado, se define como:

$$DIR(k) = \frac{1}{n_k} \sum_{i=1}^{n_k} d(x_i, y_k) \quad (4)$$

- **Coefficiente de silueta (CS):** Métrica utilizada para calcular que tan similares son las observaciones o elementos en un mismo grupo en comparación con las observaciones de otros grupos. [5]. Para una observación i se define como:

$$s(i) = \frac{b(i) - a(i)}{\max(a(i), b(i))} \quad (5)$$

dónde $a(i)$ es el promedio de disimilaridades de i con el resto de observaciones que pertenecen al mismo cluster que i , que se define como:

$$a(i) = \frac{1}{|C_I| - 1} \sum_{j \in C, i \neq j} d(i, j) \quad (6)$$

dónde $|C_I|$ es la cantidad de elementos en el cluster al cual pertenece i y $b(i)$ es el promedio de

disimilaridades de i con los elementos del cluster más cercano al cual i no pertenece (cluster “vecino”), definido como:

$$b(i) = \min_{i \neq k} \frac{1}{|C_k|} \sum_{j \in C_k} d(i, j) \quad (7)$$

dónde $|C_k|$ es la cantidad de elementos del cluster vecino.

De (5) se puede observar que el coeficiente de silueta se puede expresar también como:

$$s(i) = \begin{cases} 1 - \frac{a(i)}{b(i)} & \text{si } a(i) < b(i) \\ 0 & \text{si } a(i) = b(i) \\ \frac{b(i)}{a(i)} - 1 & \text{si } a(i) > b(i) \end{cases}$$

De lo anterior, podemos ver que el coeficiente queda definido en valores entre -1 y 1. Cuanto más cercano a 1, los grupos quedarían bien separados entre sí y claramente diferenciados. Esto se puede dar tanto por un valor de $a(i)$ pequeño (lo que indicaría que el elemento es similar a otros en su grupo) o por un $b(i)$ grande (lo que implica gran disimilaridad con el cluster vecino más cercano). Por el contrario, valores negativos cercanos a -1 indicarían que los elementos en los grupos se podrían estar asignando de forma incorrecta.

Esta última métrica en comparación con las primeras dos, nos da una información más íntegra del agrupamiento global, ya que no tiene en cuenta únicamente lo que sucede dentro del grupo, sino la separación a otros.

3. Descripción del problema en estudio

Los datos utilizados surgen de un estudio sobre las medidas implementadas en el contexto de la pandemia de Covid-19 a una muestra de empresas uruguayas y observar como fueron afectadas sus finanzas, [6], [7], [8] (ver más detalles en <https://gitlab.com/iesta.fcea.udelar/finanzas-de-emprendas-iesta>). De una muestra de 700 empresas, 112 de ellas (un 16%) respondieron a una encuesta electrónica donde se trató de cubrir todos los aspectos necesarios para la investigación, conociendo a su vez atributos de las empresas. Los datos quedaron resumidos en los siguientes bloques:

- Efectos de la pandemia sobre las finanzas de las empresas (EF).
- Medidas implementadas por las empresas para sostener el negocio (MI).

- Medidas ofrecidas por el gobierno y utilizadas en las empresas (MG).

- Cambios tecnológicos que tuvieron que realizar las empresas (CT).

Lo que se presenta en este documento surge de trabajar sobre el bloque EF, que se detalla a continuación:

Tabla 1. Bloque de variables de efectos de la pandemia sobre las finanzas de la empresa.

Variable	Descripción	Bloque	Tipo	Proporción
V1	Uso de indicadores económico-financieros	1	Estado financiero	55.4 %
V2	Flujo de fondos para evaluar liquidez	1	Estado financiero	70.5 %
V3	Afecta Flujo de Efectivo	2	Efecto en la empresa	64.3 %
V4	Afecta Volumen de Ventas	2	Efecto en la empresa	63.4 %
V5	Afecta Capital de Trabajo	2	Efecto en la empresa	50.9 %
V6	Afecta Ciclo de cuentas a cobrar	2	Efecto en la empresa	64.3 %
V7	Afecta Tiempo de abastecimiento Materias Primas	2	Efecto en la empresa	40.2 %

En cada uno de los escenarios descriptos, se evalúa el comportamiento de las distintas métricas propuestas, para observar su adecuación al problema y lograr determinar una cantidad de grupos “óptima”.

4. Resultados

Para el análisis global se trabaja con el software libre R [9], para la determinación de los clusters con el algoritmo presentado en la metodología se usa la librería *kmodes* [4] y el paquete *cluster* [10] para los coeficientes de silueta y paquete *ggplot2* [11] para la visualización.

Las visualizaciones siguientes son una forma de detectar rápidamente los patrones de respuesta dentro de cada grupo. El color más intenso representa la presencia de dicha variable dentro del cluster, es decir el porcentaje de respuestas afirmativas a la pregunta realizada (que se observa en cada columna), en contraste con el color más claro que hace referencia a la respuesta negativa o ausencia de la variable.




Fig. 1. Proporción de las variables en cada grupo (2 grupos).




Fig. 2. Proporción de las variables en cada grupo (3 grupos).




Fig. 4. Coeficiente de silueta para $k=2$.




Fig. 3. Proporción de las variables en cada grupo (4 grupos).




Fig. 5. Coeficiente de silueta para $k=3$.

Tabla 2. Métricas para validación de los grupos.

k-modes con 2 clusters	1	2		
tamaño	70	42		
withindiff (DIA)	131	77		
densidad (DIR)	1.87	1.83		
coef. silh. (CS)	0.39	0.34		
k-modes con 3 clusters	1	2	3	
tamaño	70	31	11	
withindiff (DIA)	131	51	15	
densidad (DIR)	1.87	1.65	1.36	
coef. silh. (CS)	0.26	0.26	0.37	
k-modes con 4 clusters	1	2	3	4
tamaño	56	29	11	16
withindiff (DIA)	91	44	15	17
densidad (DIR)	1.62	1.52	1.36	1.06
coef. silh. (CS)	0.08	0.29	0.27	0.38

En la Tabla 2 se pueden apreciar las métricas de forma resumida, para cada uno de los k utilizados en el algoritmo. Se puede ver inicialmente que a medida que los elementos de desagregan en más grupos, la métrica de diferencias intracluster absolutas (DIA) disminuye, lo que indica inicialmente que es sensible al valor de k . Por lo que se podría tomar como referencia mayormente las métricas de diferencias relativas (DIA) y el coeficiente de silueta para determinar una cantidad k “óptima”.




Fig. 6. Coeficiente de silueta para $k=4$.

El coeficiente de silueta, si bien es utilizado generalmente en clustering de variables numéricas, se puede adaptar para variables categóricas construyendo la matriz de disimilaridad en R a través de la función *daisy* [10] y especificando la distancia de *Gower* [12] como medida de disimilaridad. Este es un tipo de distancia para datos mixtos, dónde utiliza la medida de disimilaridad mencionada en este trabajo para datos categóricos.

A través del análisis de esta métrica para los distintos valores de k , se señala que el mayor valor (además de no presentar coeficientes negativos), se da para $k=2$. Por lo que sería conveniente utilizar esta cantidad de grupos en las pruebas del escenario 2.




Fig. 7. Escenario 1. Métricas para distintos k y arranques aleatorios. De izquierda a derecha: Dif. intracluster absolutas, relativas y coeficiente de silueta.




Fig. 8. Escenario 2. Métricas para $k=2$ y remuestreo a distintos niveles. Diferencias relativas (izquierda) y Coeficiente de silueta (derecha).

5. Discusión

Los resultados encontrados con lo hecho hasta ahora permiten ver 2 aspectos del algoritmo de clusterización utilizado.

Análisis Global:

Se puede ver que a medida que se va desagregando en más grupos, la heterogeneidad va aumentando, medida a través de 3 métricas que muestra que se llega a un k 'óptimo' en 2, decidiendo en base a la silueta (CS), ya que no hay empresas con valores negativos.

Escenario 1:

Para el escenario donde se prueban diferentes arranques (ya que es aleatorio) iterando 1000 veces se ve que la densidad media de pares discordantes (medida local) es mayor para $k = 2$, mostrando mayor dispersión relativa y mayor discontinuidad, mientras que la silueta es mayor y presenta un comportamiento con un cambio marcado al llegar a valores de 0.28.

Escenario 2:

Teniendo en cuenta que los datos utilizados son una muestra que tiene una tasa de respuesta baja (por lo tanto el número de observaciones es reducido), toma especial relevancia ver que tanta dependencia hay en los datos y de ahí el probar cambiando el tamaño de muestra de aprendizaje. Para $k = 2$ para la métrica (DIA), se observa que para un tamaño menor de muestra de aprendizaje la distribución está corrida a valores mas bajos pero con mas dispersión, mientras que a mayor tamaño de muestra de aprendizaje la variabilidad de (CS) es un poco menor y con menor dispersión en las iteraciones, resultando casi bimodal.

6. Conclusiones y futuros pasos

Se ha logrado utilizar varias métricas para el análisis de cluster y se observa el comportamiento del algoritmo bajo distintos escenarios. Lá métricas de diferencias intracluster absolutas, si bien puede brindar un primer acercamiento a la compacidad de los grupos, se observa que es susceptible al valor de k , siendo menor en la medida que k aumenta. Quizás una métrica mas fiable sea tener en cuenta las diferencias intracluster relativas (DIR) que están condicionados a la cantidad de elementos de cada grupo, o el Coeficiente de Silueta (CS), que para cada elemento brinda señales de cohesión a su grupo y de separación con el resto.

Como futuros pasos se propone:

- Estudiar el comportamiento sobre un conjunto con una cantidad mayor de observaciones y ver si estos resultados se confirman.
- Estudiar el efecto de incluir o excluir variables con fuerte presencia en una gran cantidad de grupos (que presentan proporciones altas en cada cluster).

Referencias

- [1] Tsekouras, G., Papageorgiou, D., Kotsiantis, S., Kalloniatis, C., y Pintelas, P. (2005). Fuzzy clustering of categorical attributes and its use in analyzing cultural data. *World Academy of Science, Engineering and Technology*, 1:87–91.
- [2] Álvarez-Vaz, R. y Massa, F. (2012). Determinación de tipologías de infecciones parasitarias intestinales, en escolares mediante, técnicas de clustering sobre datos binarios. Documento de Trabajo Serie DT (12 / 05) - ISSN : 1688-6453, IESTA.
- [3] Huang, Z. (1997). A fast clustering algorithm to cluster very large categorical data sets in

data mining. in kdd: Techniques and applications. Technical report.

- [4] Weihs, C., Ligges, U., Luebke, K., y Raabe, N. (2005). Klar analyzing german business cycles. En Baier, D., Decker, R., y Schmidt-Thieme, L., editores, *Data Analysis and Decision Support*, pp. 335–343, Berlin. Springer-Verlag.
- [5] Rousseeuw, P. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis *Journal of Computational and Applied Mathematics*, 20:53-65
- [6] Brealey, R., Myers, S., y Allen, F. (2011). *Principles of Corporate Finance*. McGraw-Hill / Irwin., New York.
- [7] Graham, J. R. y Harvey, C. R. (2001). The theory and practice of corporate finance: Evidence from the field. *Journal of Financial Economics*, 60(2):187–243.
- [8] Ross, S., Westerfield, R., y Jaffe, J. (2012). *Finanzas Corporativas*. McGraw-Hill/Interamericana Editores, México.
- [9] R Core Team (2021). *R: A Language and Environment for Statistical Computing*. R Foundation for Statistical Computing, Vienna, Austria.
- [10] Maechler, M., Rousseeuw, P., Struyf, A., Hubert, M., Hornik, K.(2021). cluster: Cluster Analysis Basics and Extensions. R package version 2.1.2.
- [11] H. Wickham. ggplot2: Elegant Graphics for Data Analysis. Springer-Verlag New York, 2016.
- [12] Gower, J. C. (1971) A general coefficient of similarity and some of its properties, *Biometrics* 27, 857–874.